

1.1

$$X^T X w = X^T y$$

המשוואה הזו היא המשוואה הנורמלית (normal equations) והיא נובעת מהעובדה ש- $X^T y$ היא הרכיב של y שממוקד על ידי X .

$$\hat{w} = (X^T X)^{-1} X^T y$$

המשוואה הזו היא המשוואה הנורמלית (normal equations) והיא נובעת מהעובדה ש- $X^T y$ היא הרכיב של y שממוקד על ידי X .

המשוואה הזו היא המשוואה הנורמלית (normal equations) והיא נובעת מהעובדה ש- $X^T y$ היא הרכיב של y שממוקד על ידי X .

$$X^T X w \perp \ker(X) \iff X^T y \perp \ker(X) \iff X^T y = X^T X w$$

כלומר, $X^T X w$ הוא הרכיב של $X^T y$ שממוקד על ידי X .

המשוואה הזו היא המשוואה הנורמלית (normal equations) והיא נובעת מהעובדה ש- $X^T y$ היא הרכיב של y שממוקד על ידי X .

$$(X^T X w) \perp \ker(X) \iff w^T X^T X w = 0 \iff w^T X^T X w = 0 \iff w \in \ker(X)$$

כלומר, $X^T X w$ הוא הרכיב של $X^T y$ שממוקד על ידי X .

המשוואה הזו היא המשוואה הנורמלית (normal equations) והיא נובעת מהעובדה ש- $X^T y$ היא הרכיב של y שממוקד על ידי X .

1.2 Projection Matrices

Let $V \in \mathbb{R}^{d \times k}$ be a matrix with k columns v_1, \dots, v_k that are orthonormal. Then the projection matrix onto the column space of V is given by $P = \sum_{i=1}^k v_i v_i^T$.

(a) show that P is symmetric $\Rightarrow P^T = P$

$$P^T = \left(\sum_{i=1}^k v_i v_i^T \right)^T = \sum_{i=1}^k (v_i v_i^T)^T = \sum_{i=1}^k v_i v_i^T = P$$

(b) $v_i v_i^T$ is a rank 1 matrix

המשוואה הזו היא המשוואה הנורמלית (normal equations) והיא נובעת מהעובדה ש- $X^T y$ היא הרכיב של y שממוקד על ידי X .

$$P v_j = v_j \iff \sum_{i=1}^k v_i v_i^T v_j = v_j \iff \sum_{i=1}^k \delta_{ij} v_i = v_j$$

כלומר, $P v_j = v_j$ עבור כל j .

$$\lambda v_j = v_j \iff P v_j = \lambda v_j = v_j$$

כלומר, $\lambda = 1$ עבור כל j .

(c) show that $VV^T V = V$, $PV = V$

Let $v \in \mathbb{R}^n$ and $v \in V$. Then v can be written as $v = \sum_{j=1}^k a_j v_j$

$$PV = \sum_{i=1}^k v_i v_i^T \sum_{j=1}^k a_j v_j = \sum_{i=1}^k \sum_{j=1}^k a_j v_i v_i^T v_j = \sum_{i=1}^k \sum_{j=1}^k a_j v_i \delta_{ij} = \sum_{i=1}^k a_i v_i = V$$

(d) $P^2 = P$

From part (c) we know that $PV = V$. Also, $P^2 = P$ is equivalent to $P(PV) = PV$. Since $PV = V$, we have $P(V) = V$. This shows that P is a projection matrix.

$$P^2 = (U D U^T)(U D U^T) = U D D U^T = U D U^T = P$$

(e) Prove that $(I - P)P = 0$

$$(I - P)P = 0 \Leftrightarrow P - P^2 = 0 \Leftrightarrow P = P^2 \quad \text{(idempotent)}$$

1.3 Least Squares

6. Show that if $X^T X$ is invertible, the general solution we derived in the recitation =

$$X^T X \hat{w} = X^T y \Leftrightarrow (X^T X)^{-1} (X^T X) \hat{w} = (X^T X)^{-1} X^T y \Leftrightarrow \hat{w} = (X^T X)^{-1} X^T y$$

$$\hat{w} = V \Sigma^+ U^T y$$

$$X = U \Sigma V^T \Rightarrow X^T X = (U \Sigma V^T)^T (U \Sigma V^T) = V \Sigma^T U^T U \Sigma V^T = V \Sigma^T \Sigma V^T = V \Sigma^2 V^T$$

Since $X^T X$ is invertible, Σ^2 is invertible. Therefore, $(X^T X)^{-1} = (V \Sigma^2 V^T)^{-1} = V \Sigma^{-2} V^T$.

3) הבה נסתכל על $X^T Y = U \Sigma U^T$ (כאן U ו- V הם מטריצות אורתוגונליות)

$$[X^T X]^{-1} = [U \Sigma U^T]^{-1} = U \Sigma^{-1} U^T$$

כלומר $X^T X$ היא מטריצה סימטרית חיובית, ולכן הפיכה.

$$X^T = (U \Sigma V^T)^T = V \Sigma^T U^T$$

$$[X^T X]^{-1} X^T = U \Sigma^{-1} U^T V \Sigma^T U^T = U \Sigma^{-1} \Sigma^T U^T = U (\Sigma^{-1} \Sigma^T) U^T = U \Sigma^{+T} U^T$$

ובנוסף $\Sigma^+ \Sigma = I$ ו- $\Sigma \Sigma^+ = I$ (כאן Σ היא מטריצה $n \times n$).

$$\hat{w} = [X^T X]^{-1} X^T y \Rightarrow \hat{w} = U \Sigma^+ U^T y$$

(7) Show that $X^T X$ הפיכה $\Leftrightarrow \text{span}\{x_1, \dots, x_n\} = \mathbb{R}^d$

$$\Leftrightarrow \text{ker}(X) = \{0\} \Leftrightarrow \text{ker}(X^T X) = \{0\} \Leftrightarrow \text{Ran}(X^T X) = \mathbb{R}^d \Leftrightarrow \text{Ran}(X) = \mathbb{R}^d$$

כלומר, X היא מטריצה מלאה (full rank).

(8) אנו רוצים למצוא את הפתרון \hat{w} של $X^T X w = X^T y$ (כאן X היא מטריצה $n \times d$).

הפתרון \hat{w} הוא הנקודה הקרובה ביותר ל- y במרחב $\text{Ran}(X)$.

$$X = U \Sigma V^T \quad \text{כאן } U, V \text{ מטריצות אורתוגונליות ו-} \Sigma \text{ מטריצה סיגמא}$$

$$U^T U = I, U U^T = I, V^T V = I, V V^T = I$$

$$\hat{w} = \sum_{i=1}^n \frac{u_i^T y}{\sigma_i} v_i$$

$$\text{rank}(X^T X) = \text{rank}(X) = r$$

לפיכך

$$\hat{w} = \|U \Sigma V^T \hat{w} - y\| = \|U^T(U \Sigma V^T \hat{w}) - U^T(y)\| = \|\Sigma V^T \hat{w} - U^T(y)\|$$
 נשאר (נשאר נכון בעת כלל משימה)

אפשר

$$= \|\Sigma V^T \hat{w} - U^T(y)\| = \left\| \sum_{i=1}^r (\sigma_i v_i^T \hat{w}_i - u_i^T y) \right\| + \sum_{j=r+1}^m \hat{w}_j^T y_j$$
 Transilience $\rightarrow \sigma_{dim} = 0$

נסתכל ב (A) נניח להכין את $\|x - y\|$ של $w \in \text{argmin} \|x - y\|$
 "min" ריבוקרטי (פולינום) בן 0 (א) מלבד בזמן
 ממשית (המשפט האנליטי האחר, הריבוקרטי הריבוקרטי)
 כי ממשית שונה X (ואם ר' וסמך זה נכון אולי שיהיה זה
 ר' שונה (וראשית) בזמן גורם עקבית.
 את שבתק עשיתי (א) עדיין פסבוקרטי הריבוקרטי. איזה
 סט (המשפט) מ-2 ר' וסמך מ של ה (א) אסמך + (א) אסמך
 אסמך (המשפט) אסמך שבתק אסמך (א) אסמך (א) אסמך
 אסמך (א) אסמך \sum האסמך (א) אסמך (א) אסמך

$$\Sigma = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \\ & & & 0 \end{bmatrix}$$

$$U^T \hat{w} = \begin{bmatrix} \hat{w}_1^T u_1 \\ \vdots \\ \hat{w}_r^T u_r \\ 0 \\ \vdots \end{bmatrix}$$

אסמך, אסמך \bar{w} אסמך אסמך

$$\|\bar{w}\| = \sum_{i=1}^d \bar{w}_i^2 = \sum_{i=1}^r \bar{w}_i^2 + \sum_{j=r+1}^d \bar{w}_j^2 \geq \sum_{i=1}^r \bar{w}_i^2 = \sum_{i=1}^r \hat{w}_i^2 = \|\hat{w}\|^2$$

IML -Ex 2

אביב אוחיון 313410458

שאלה 12:

בשאלה זו הורדתי את הפיצרים של id, date, long, lat.

הסיבור לכך הם שעבור הפיצר של id, הערך הזה לא משחק חשיבות בשווי של הדירות אלא רק מייצג מי הבעלים של הדירה. עבור ה פיצרים long, lat אלו פיצרים אשר מתארים בסופו של דבר קורדינטה במרחב, אשר שקולה פחות או יותר למה שמתאר הפיצר zipcode רק שבמקרה זה זה פיצר בודד ועל כן יותר יעיל להשתמש בו מאשר בהם. לגבי הפיצר של התאריך, אחרי מעבר על ערכי התאריכים ראיתי שהם רק עבור השנים 2014 2015, מהסתכלות זריזה באינטרנט מחירי הדירות לרוב משתנים (ברמה המייחסת חשיבות) אחת ללפחות 7 שנים, ועל כן העדפתי להוריד את העמודה הזו גם על מנת להקל על החישובים.

שאלה 13:

הפיצר שהחלטתי לבצע עבורו one hot encoding היה הפיצר של ה zipcode. לפיצר זה אין יחס סדר ועל כן חישובים ניומרים התלויים בו צפויים לקבל תוצאות משונות, עם זאת עקב מה שהסברתי להעיל בשאלה 12, יש לו עדיין חשיבות אז לא רציתי להוריד אותו לגמריי כמו פיצרים אחרים.

שאלה 15:

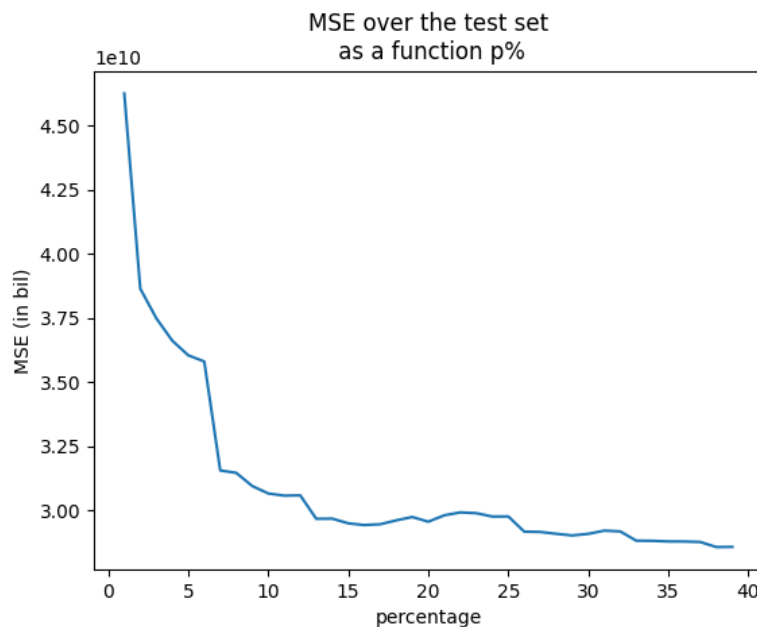
מה שנוכל ללמוד מהקשר בין כמות הפיצרים לבין ערכים הסינגולרים הוא על היחס הלינארי בניהם, כלומר, ככל שהערכים הסינגולרים של מטריצה הפיצרים, דגימות יהיו יותר קרובים ל 0, זה יצביע על כך שעמודות הטבלה יהיו תלויות לינארית אלו באלו. מצב של תלות לינארית מושלמת קשה להשגה עקב הרבה גורמים חיצוניים ולכן גם "כמעט תלות" תצביע לנו על יחס הדוק בין עמודות הטבלה (הפיצרים התלויים למודל).

על כן, ככל שיותר דגימות יתנו לנו ערכים סינגולרים יותר קטנים השואפים ל אפס, כמות המידע שנוכל להסיק תקטן, כיוון כאילו פיצר אחד לא כזה השפיע על התוצאה של הפיצר השני ולהיפך (זה בדיוק התלות הלינארית), לעומת זאת, פיצרים בעלי ערכים סינגולרים מאוד גדולים ורחוקים זה מזה יצביע לנו על קשר

הרבה יותר חזק אחד לשני כי תזוזה של תוצאת פ'יצר אחד תשפיע מאוד על תוצאת הפ'יצר השני וליהפך.

נסיק מכך שכיוון שיש יותר פיצרים (במקרה של איך שאני ממשתי 15 עמודות) ככה הערכים הסינגורלים ישאפו ל 0 כלומר תיהיה בניהם תלות לינארית. מהגרף שמתאר כך ניתן לראות שכבר מהפ'צר ה 3 או 4 הערכים שואפים ל 0 ולכן כבר יש "כמעט תלות לינארית" בניהם משמע זה יהיה המקרה הסינגורלי (המקרה הלא הפיך)

שאלה 16



ניתן לראות שככל שאנחנו מגדילים את אחוז השורות שאנחנו "מאמנים" ככה ערך הסטייה MSE יורד גם כן ומהר מאוד מתייצב על סביבות B25. ההתכנסות הזו קוראת כבר לאחר שאנחנו דוגמים כרבע מהשורות מהחלק במודל שעליו אנחנו מתאמנים, נסיק מכך שנוכל כבר מכמות יחסית קטנה של דגימות עבור הערכים האלו לקבל מידע יחסית נאמן ובעל סטייה קבוע מהערכי ה γ המקוריים. הערה, עקב חוסר מקום לאלוקציה של זיכרון, האיטרציה רצה עד 40 אחוז, עם זאת לאחר שניסתי כמה פעמים להרציץ את החישובים עם אחוזים התחלים מ 50 אחוז ולא מ 1 וכו, נוכחתי לגלות שההתיצבות נישארת זהה והגרף יתכלס פחות או יותר ל MSE שהוא B25.

שאלה 17

ראשית, אנחנו נוכל להסיק מהגרפים המתארים את קורולציית פרסון מידע על כמה מידע נוכל להסיק (אם בכלל) בין פיצ'ר מסויים לעמודת המחרים. הדרך שבא זה הקורולציה מתבטאת בגרף על ידי זה שמצד אחד המטריצת השונות המשותפת מתארת לנו "לאיזה כיוון" הדגימות מתקדמות ביחס ל γ וקטור ומצד שני על ידי חלוקה בכפל בין השונות הנורמאלית של כל וקטור "מנרמלת" את היחסים בניהם ומדגימה עד כמה "חזק" הקשר בניהם. מצב זה מבטא בדיוק את הקשר הלינארי בין בכמה חזק פיצ'ר כלשהו לוקטור הresponse. כאשר הערכים נעים בין $[-1,1]$ (הקשר החזק ביותר 1 והחלק ביותר -1)

על כן, גרפים בהם ניתן לראות שככל שציר ה x עולה ככה עולה ה y (או יורד) בצורה יחסית רציפה הם גרפים אשר נוכל להסיק מהם מידע כי הקשר קיים שם. מנגד, גרפים אשר לא מראים בהכרח קשר (לינארי) בין הגדילה של x לבין איך מושפע ה y לא יעזרו לנו כל כך כי לא נוכל להסיק אם בכלל קיים קשר בין הזוג הנ"ל.

קשר טוב – בעל ערך 0.7 ניתן לראות שאפשר להעביר קו ישר יחסית בקלות בין כל הערכים הכי גבוהים בעל שיפוע "חזק" מאוד



קשר רע - בעל ערך 0.39, ניתן לראות שאין יחס לינארי בין התקדמות ה ערכי ה x לבין ערכי ה y הם פחות או יותר זהים לא משנה מה הפי'צר x יהיה ולכן הישר המחבר בניהם יהיה יחסית מאוזן

